

NemoClaw

AI 에이전트를 위한 작업장 — GPU 위에서 일하는 법

Contents

1. NemoClaw란 무엇인가 — AI 에이전트의 실행환경

2. GPU와 로컬 모델 — 실제 답을 만드는 곳

3. 데모 — OpenClaw에서 미니 게임 만들기

전체 그림

NemoClaw 전체 아키텍처 한눈에 보기

에이전트 · 도구 · 모델 · 인프라가 어떻게 맞물려 있는지.

NVIDIA NemoClaw: Secure OpenClaw Agent Execution on OpenShell




Figure: NemoClaw separates host-side orchestration, OpenShell gateway enforcement, sandboxed agent execution, and policy-controlled external communication.

OpenClaw vs NemoClaw

OpenClaw는 에이전트가 일하는 엔진, NemoClaw는 그 엔진을 안전하게 운영하기 위한 래퍼.

같은 에이전트라도 NemoClaw 안에서는 네트워크 · 권한 · 추론 경로가 통제됩니다.

OPENCLAW

에이전트 엔진

에이전트가 실제로 일하는 런타임 — 파일을 쓰고, 명령을 실행하고, 세션을 유지합니다.

역할

AI Agent Runtime

핵심 기능

세션 관리 · 도구 사용 · 작업공간 조작

실행 위치

일반 호스트 또는 gateway runtime

관점

에이전트가 무엇을 하는가

NEMOCLAW

보안 · 운영 래퍼

OpenClaw를 sandbox 안에서 실행하고 네트워크·권한·추론 경로를 통제하는 reference stack.

역할

OpenClaw를 안전하게 실행하는 운영 스택

핵심 기능

Sandbox · Policy · Gateway · Inference Route

실행 위치

OpenShell container/sandbox 내부

관점

에이전트가 어디서·얼마나 안전하게 일하는가

왜 GPU가 필요한가

LLM 추론은 거대한 행렬 곱셈의 연속입니다.

토큰 하나를 만들 때마다 수십억 개의 곱셈·덧셈을 해야 하고, 이것을 CPU로 하면 한 문장 답하는 데 수 분이 걸립니다. GPU는 같은 연산을 **수천 개 코어로 동시에 처리**합니다.

LLM 추론은 거대한 행렬 곱셈의 연속입니다.

CPU: 한 명의 엘리트 우편 배달부

파스칼 가능항, 하면 개한 판속해야 곱셈, 거리, 처리하고 배달 각각 하나씩 하나면, 방법적이고 하고 수선했습니다.

한 문자 전송
분 단위 소요




GPU: 수천 개의 로봇 팔 군단

로론에 마은리수하의 로봇폴선트

그거 한순간에 하나씩, 전차로 3평사적으로 정사를 언해 매임 골러라는 처리를 동시하다.

순식간에
처리 완료



1. 수천 개의 협업 손
(병렬 코어 수: 수천 개)
모두가 한꺼번에 움직여요.
(동시에 곱셈/덧셈)



2. 초고속 자재 공급 벨트
(메모리 대역폭: 수백 GB/s)
협업 손들에게 재료를 엄청난
속도로 부어줘요.
(거대한 가중치를 빠르게 읽음)



3. 한순간에 처리 완료
(추론 가속: 수십~수백 배)
CPU는 하나씩, 우리는 한꺼번에!
결과가 금방 나와요.
(CPU 대비 응답 속도)

모델을 NemoClaw에 올리는 흐름

학습된 가중치 파일이 GPU 메모리에 올라가야 비로소 추론이 시작됩니다.

NemoClaw는 이 과정을 자동화합니다 — 모델 선택부터 서빙까지 한 번 띄워두면, 에이전트가 같은 모델을 공유해서 사용합니다.

STEP 1 모델 선택

오픈소스 LLM 중 용도/크기에 맞는 모델 선택 (예: Llama-3-8B)

STEP 2 GPU 로딩

가중치 파일을 VRAM에 올림.
모델 크기에 따라 12~80GB 필요

STEP 3 서빙

NemoClaw가 API 형태로 모델을 노출. 여러 에이전트가 공유

STEP 4 에이전트 호출

AGENT.md·Skills이 이 모델을 부르면 토큰 단위로 응답 생성

Thank you